



Júpiter - Sistema de Gestão Acadêmica da Pró-Reitoria de Graduação

Escola Politécnica

Eng de Sistemas Eletrônicos

Disciplina: PSI0325 - Fundamentos de Adaptação e Aprendizado de Máquina Fundamentals of Adaptation and Machine Learning

Créditos Aula: 3
Créditos Trabalho: 0
Carga Horária Total: 45 h
Tipo: Semestral
Ativação: 15/07/2026 **Desativação:**

Ementa

A disciplina explora o processo central pelo qual os sistemas de IA adquirem conhecimento e ajustam seu comportamento. O programa inicia com o Aprendizado de Máquina (ML) Básico (Módulo I), introduzindo os paradigmas supervisionado (Regressão, SVM) e não supervisionado (K-Means, PCA), focando na extração de padrões e na construção de modelos preditivos a partir dos dados. Em seguida, o curso aborda a Avaliação e Otimização (Módulo II), onde são estudadas métricas de desempenho e estratégias para mitigar desafios como overfitting. A essência da Adaptação (Módulo III) é detalhada através das Redes Neurais Artificiais (ANN), onde o algoritmo de Backpropagation e a Descida do Gradiente são apresentados como os mecanismos-chave que permitem aos modelos ajustar seus pesos e melhorar de forma iterativa, culminando com uma visão dos conceitos avançados como Aprendizado por Reforço e Transfer Learning (Módulo IV), que governam a capacidade dos sistemas de se adaptar continuamente a novos ambientes e tarefas.

The discipline explores the core process by which AI systems acquire knowledge and adjust their behavior. The curriculum begins with Basic Machine Learning (ML) (Module I), introducing the supervised (Regression, SVM) and unsupervised (K-Means, PCA) paradigms, focusing on pattern extraction and the construction of predictive models from data. Next, the course covers Evaluation and Optimization (Module II), where performance metrics and strategies to mitigate challenges like overfitting are studied. The essence of Adaptation (Module III) is detailed through Artificial Neural Networks (ANNs), where the Backpropagation algorithm and Gradient Descent are presented as the key mechanisms that allow models to adjust their weights and improve iteratively, culminating with an overview of advanced concepts such as Reinforcement Learning and Transfer Learning (Module IV), which govern the ability of systems to continuously adapt to new environments and tasks.

Objetivos

A disciplina tem por objetivo apresentar e discutir aspectos fundamentais de filtros adaptativos e de aprendizado de máquina supervisionado, em especial, redes neurais artificiais. Os objetivos incluem não só desenvolver a teoria matemática de algumas realizações, mas também introduzir a implementação computacional das soluções em Python. Em filtros adaptativos, serão considerados algoritmos da família least-mean-square (LMS) para adaptar os coeficientes de filtros com resposta ao pulso unitário finita (FIR). Em aprendizado de máquina, será considerada a rede neural perceptron multicamada (multilayer perceptron - MLP) e questões relacionadas ao seu treinamento e avaliação.

The aim of the course is to present and discuss fundamental aspects of adaptive filters and supervised machine learning, especially, artificial neural networks. The objectives include not only developing the mathematical theory of some achievements, but also introducing implementation of solutions in Python. In adaptive filters, least-mean-square (LMS)-based algorithms will be considered to adapt the coefficients of finite impulse response (FIR) filters. In machine learning, the multilayer perceptron (MLP) network and issues related to its training and evaluation will be considered.

Conteúdo Programático

- 1- Introdução: aplicações de filtragem adaptativa e aprendizado de máquina
 - Motivação para uso de filtros adaptativos e redes neurais artificiais
 - Classificação e regressão
- 2- Regressão linear
 - Regressão linear simples e multivariada

- O problema do sobreaprendizado (overfitting)
- Relação com a solução de Wiener
- Propriedades da matriz de autocorrelação
- Propriedades do erro quadrático médio (mean-square error - MSE)

3- Algoritmo LMS

- Algoritmos Steepest Descent e LMS: obtenção e convergência
- Algoritmos derivados do LMS: LMS normalizado, Leaky-LMS, algoritmos LMS com passo variável
- Modos de treinamento: estocástico, batch e mini-batch

4- Neurônio de Rosenblatt e rede MLP

- O neurônio de Rosenblatt
- Regressão logística
- O algoritmo de retropropagação (backpropagation)
- Rede MLP e o teorema da aproximação universal

5- Evitando mínimos locais e overfitting

- Funções de ativação: sigmoideal, tangente hiperbólica, ReLU e suas variantes, Softmax
- Funções objetivo: MSE, entropia cruzada, entropia cruzada categórica, entropia relativa; técnicas de regularização
- Estratégias de inicialização de pesos e vieses: Xavier e He
- Passo de adaptação: learning rate annealing
- Estratégias de treinamento e otimizadores: Mini-batch, Dropout, Momentum, root mean squared propagation (RMSprop) e adaptive moment estimation (Adam)
- Partição de dados e validação cruzada

6- Medidas de desempenho

- Erro absoluto médio e erro quadrático médio
- Matriz de confusão
- Acurácia e taxa de erro
- Precisão
- Sensibilidade e F1-score
- Especificidade e taxa de falsos positivos
- Coeficiente de correlação de Matthew
- Curva ROC

7- Técnicas de redução de dimensionalidade

- Análise de componentes principais
- Análise de discriminante linear

1- Introduction: applications of adaptive filtering and machine learning

- Motivation for use of adaptive filters and neural networks
- Classification e regression

2- Linear regression

- Simple and multivariate linear regression
- The problem of overfitting
- Relation to Wiener solution
- Properties of the autocorrelation matrix
- Properties of the mean-square error (MSE)

3- LMS algorithm

- Steepest Descent and LMS: derivation and convergence
- LMS-based algorithms: normalized LMS, Leaky-LMS, LMS with variable step-size
- Training modes: stochastic, batch and mini-batch

4- Rosenblatt neuron and MLP network

- Rosenblatt neuron
- Logistic regression
- Backpropagation algorithm
- MLP and the universal approximation theorem

5- Avoiding local minima and overfitting

- Activation functions: sigmoid, hyperbolic tangent, ReLU and its variants, Softmax
- Objective functions: MSE, cross-entropy, categorical cross-entropy, relative entropy; regularization techniques
- Strategies of weights and bias initialization: Xavier and He
- Adaptation steps: learning rate annealing
- Training strategies and optimizers: Mini-batch, Dropout, Momentum, root mean squared propagation (RMSprop) e adaptive moment estimation (Adam)
- Splitting Data and Cross-validation

6- Performance measures

- Mean absolute error and mean squared error
- Confusion matrix

- Accuracy and error rate
- Precision
- Sensitivity and F1-score
- Specificity and false positive rate
- Matthew's correlation coefficient
- ROC curve

7- Dimensionality reduction techniques

- Principal component analysis
- Linear discriminant analysis
- LMS-based algorithms: normalized LMS, Leaky-LMS, LMS with variable step-size
- Training modes: stochastic, batch and mini-batch

4- Rosenblatt neuron and MLP network

- Rosenblatt neuron
- Logistic regression
- Backpropagation algorithm
- MLP and the universal approximation theorem

5- Avoiding local minima and overfitting

- Activation functions: sigmoid, hyperbolic tangent, ReLU and its variants, Softmax

ESCOLA POLITÉCNICA DA UNIVERSIDADE DE SÃO PAULO

(cont.) Anexo D / Annex D

- Objective functions: MSE, cross-entropy, categorical cross-entropy, relative entropy; regularization techniques

- Strategies of weights and bias initialization: Xavier and He
- Adaptation steps: learning rate annealing
- Training strategies and optimizers: Mini-batch, Dropout, Momentum, root mean squared propagation (RMSprop) e adaptive moment estimation (Adam)
- Splitting Data and Cross-validation

6- Performance measures

- Mean absolute error and mean squared error
- Confusion matrix
- Accuracy and error rate
- Precision
- Sensitivity and F1-score
- Specificity and false positive rate
- Matthew's correlation coefficient
- ROC curve

7- Dimensionality reduction techniques

- Principal component analysis
- Linear discriminant analysis

Métodos de Ensino

Aulas teóricas, aulas ativas e práticas.

Theoretical classes, active classes, and practical classes.

Instrumentos e Critérios de Avaliação

Método de Avaliação

Exercícios e provas

Critério de Avaliação

Média ponderada de exercícios e provas.

Norma de Recuperação

Uma prova ou exercício.

Bibliografia Básica

- [1] S. Haykin, "Adaptive Filter Theory", 5th ed., Pearson, 2013
- [2] A. H. Sayed, "Adaptive Filters", John Wiley & Sons, 2008.
- [3] P. S. R. Diniz (Ed.), "Signal Processing and Machine Learning Theory", Academic Press, 2024.
- [4] S. Haykin, "Neural Networks and Learning Machines", Prentice Hall, 2008.
- [5] I. Goodfellow, Y. Bengio, and A. Courville. "Deep Learning", MIT Press, 2016. Disponível em www.deeplearningbook.org
- [6] C. M Bishop, "Deep Learning: Foundations and Concepts", Springer, 2024.

[7] R. O. Duda, P. E. Hart and D. G. Stork. "Pattern Classification", Wiley, 2001.

[8] A. H. Sayed, "Inference and Learning from Data, vol. 3: Learning", Cambridge University Press, 2022.

Bibliografia Complementar

Não se aplica.

Objetivos de Desenvolvimento Sustentável (ONU)

nº 9) *Indústria, Inovação e Infraestrutura*: construir infraestrutura resiliente, promover a industrialização inclusiva e sustentável, e fomentar a inovação;

nº 11) *Cidades e Comunidades Sustentáveis*: tornar as cidades e os assentamentos humanos inclusivos, seguros, resilientes e sustentáveis;

Docente(s) Responsável(eis)

1488469 - Magno Teófilo Madeira da Silva

[Clique para consultar os requisitos para PSI0325](#)

[Clique para consultar o oferecimento para PSI0325](#)

Créditos | Fale conosco

© 1999 - 2026 - Superintendência de Tecnologia da Informação/USP